Теория вероятностей и математическая статистика

Линейные комбинации случайных величин. Ковариация и корреляция.

Глеб Карпов

Программы БИ, УЦП, ТАДвБ ВШБ ВШЭ.

Линейная комбинация случайных величин

Математическое ожидание комбинации

- Часто важно анализировать поведение суммы двух или более случайных величин
- В основном мы хотим понять, как ведет себя переменная $T = aX \pm bY$, каковы ее характеристики.
- Линейное свойство математического ожидания: $E[aX \pm bY] = aE[X] \pm bE[Y]$.

$$E[T] = \sum_{i=1}^{n}\sum_{j=1}^{m}(ax_i \pm by_j)P(X = x_i, Y = y_j) =$$

$$\sum_{i=1}^{n}\sum_{j=1}^{m} ax_i P(X = x_i, Y = y_j) \pm \sum_{i=1}^{n}\sum_{j=1}^{m} by_j P(X = x_i, Y = y_j) =$$

$$a\sum_{i=1}^{n} x_i \underbrace{\sum_{j=1}^{m} P(X = x_i, Y = y_j)}_{\text{marginal for } X} \pm b\sum_{j=1}^{m} y_j \underbrace{\sum_{i=1}^{n} P(X = x_i, Y = y_j)}_{\text{marginal for } Y} =$$

$$a\sum_{i=1}^{n} x_i P(X = x_i) \pm b\sum_{j=1}^{m} y_j P(Y = y_j) = aE[X] \pm bE[Y]$$

Линейная комбинация случайных величин

Но дисперсия - это уже совсем другая история...

- Нас интересует $Var[T] = Var[aX \pm bY]$.
- Применим сокращенную формулу для дисперсии:

$$
\begin{aligned}
Var[T] = E[T^2] - (E[T])^2 &= E[(aX \pm bY)^2] - (aE[X] \pm bE[Y])^2 \\
&= E[a^2X^2 \pm 2abXY + b^2Y^2] - ((aE[X])^2 \pm 2abE[X]E[Y] + (bE[Y])^2) \\
&= a^2E[X^2] \pm 2abE[XY] + b^2E[Y^2] - a^2(E[X])^2 \mp 2abE[X]E[Y] - b^2(E[Y])^2 \\
&= a^2Var[X] + b^2Var[Y] \pm 2ab\Big(E[XY] - E[X]E[Y]\Big)
\end{aligned}
$$

- В процессе использовали свойство линейности математического ожидания.
- Слагаемое $E[XY] - E[X]E[Y]$ называется **ковариацией** X и Y.
- Определение: $Cov(X, Y) = E[XY] - E[X]E[Y]$.

Ковариация и независимость

Утверждение: Если X и Y - независимые случайные величины, то $E[XY] = E[X]E[Y]$

Proof

Используем определение независимости величин:

$$\forall x_i,\ \forall y_j:\ P_X\left(X = x_i\right) P_Y\left(Y = y_j\right) = P(\{X = x_i\} \cap \{Y = y_j\}) = P\left(X = x_i, Y = y_j\right)$$

$$E[XY] = \sum_{i=1}^{n}\sum_{j=1}^{m} x_i y_j P(X = x_i, Y = y_j) = \sum_{i=1}^{n}\sum_{j=1}^{m} x_i y_j P_X(x_i) P_Y(y_j)$$
$$= \sum_{i=1}^{n} x_i P_X(x_i) \sum_{j=1}^{m} y_j P_Y(y_j) = E[X]E[Y].$$

Будьте внимательны: обратное утверждение неверно!

Логика высказываний: независимость и ковариация

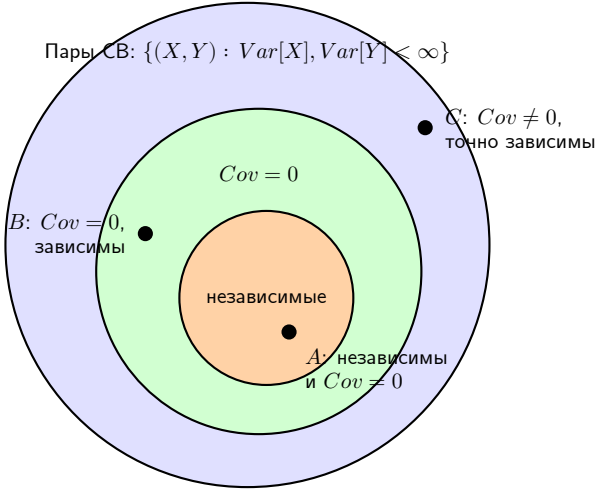

Случай C используем для детекции зависимости: $Cov \neq 0 \Rightarrow$ зависимы.

Корреляция

- Ковариация не является хорошей мерой зависимости, поскольку она зависит от масштабов X и Y.
- Идея: нормализовать ковариацию и избавиться от масштабов.
- Корреляция:

$$Corr(X, Y) = \frac{Cov(X, Y)}{\sqrt{Var[X]Var[Y]}}$$

- Она строго ограничена от -1 до 1 и:

$$Corr(X, Y) = 1 \leftrightarrow Y = kX + b,\ k > 0$$
$$Corr(X, Y) = -1 \leftrightarrow Y = -kX + b,\ k > 0$$

- Важно: Если переменные независимы, то их ковариация (и корреляция) равна нулю. Обратное утверждение НЕВЕРНО. Ковариция может быть равной нулю, но при этом величины являются зависимыми.

Пример:

Случайный вектор (X, Y) принимает значения $(-1, 1)$ и $(2, -2)$ с вероятностями $\frac{2}{3}$ и $\frac{1}{3}$.

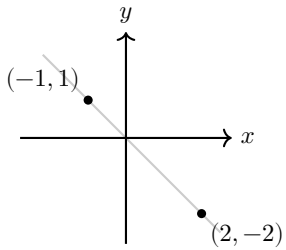

	$Y = 1$	$Y = -2$
$X = -1$	$\frac{2}{3}$	0
$X = 2$	0	$\frac{1}{3}$

1. Найдите маргинальные функции вероятности для X и Y.
2. Независимы ли X и Y?
3. Найдите ковариацию (и корреляцию) между X и Y.

Решение задачи

1. Маргинальные функции вероятности

Для X:

$$P(X=-1)=\sum_j P(X=-1,Y=y_j)=\frac{2}{3}+0=\frac{2}{3}$$

$$P(X=2)=\sum_j P(X=2,Y=y_j)=0+\frac{1}{3}=\frac{1}{3}$$

Для Y:

$$P(Y=1)=\sum_i P(X=x_i,Y=1)=\frac{2}{3}+0=\frac{2}{3}$$

$$P(Y=-2)=\sum_i P(X=x_i,Y=-2)=0+\frac{1}{3}=\frac{1}{3}$$

Пример

Проверка независимости

Проверим условие независимости для пары:

$$P(X=-1,Y=1)=\frac{2}{3} \quad \text{и} \quad P(X=-1)P(Y=1)=\frac{2}{3}\cdot\frac{2}{3}=\frac{4}{9}\neq\frac{2}{3}$$

Ответ: X и Y **не независимы**.

Пример

Ковариация и корреляция

Сначала найдем математические ожидания:

$$E[X] = (-1) \cdot \frac{2}{3} + 2 \cdot \frac{1}{3} = 0$$

$$E[Y] = 1 \cdot \frac{2}{3} + (-2) \cdot \frac{1}{3} = 0$$

Теперь найдем $E[XY]$:

$$E[XY] = (-1) \cdot 1 \cdot \frac{2}{3} + 2 \cdot (-2) \cdot \frac{1}{3} = -\frac{2}{3} - \frac{4}{3} = -2$$

Пример

Ковариация:

$$Cov(X,Y) = E[XY] - E[X]E[Y] = -2 - 0 \cdot 0 = -2$$

Для корреляции найдем дисперсии:

$$E[X^2] = (-1)^2 \cdot \frac{2}{3} + 2^2 \cdot \frac{1}{3} = \frac{2}{3} + \frac{4}{3} = 2$$
$$Var[X] = E[X^2] - (E[X])^2 = 2 - 0 = 2$$

$$E[Y^2] = 1^2 \cdot \frac{2}{3} + (-2)^2 \cdot \frac{1}{3} = \frac{2}{3} + \frac{4}{3} = 2$$
$$Var[Y] = E[Y^2] - (E[Y])^2 = 2 - 0 = 2$$

Пример

Корреляция:

$$Corr(X,Y) = \frac{Cov(X,Y)}{\sqrt{Var[X]Var[Y]}} = \frac{-2}{\sqrt{2 \cdot 2}} = \frac{-2}{2} = -1$$

Корреляция равна -1, что означает полную отрицательную линейную зависимость между X и Y (здесь $Y = -X$).

Пример зависимости при нулевой корреляции

Случайный вектор (X, Y) равновероятно принимает одно из четырёх значений на окружности:

$$(2, 0), \quad (0, 2), \quad (-2, 0), \quad (0, -2),$$

каждое с вероятностью $\frac{1}{4}$.

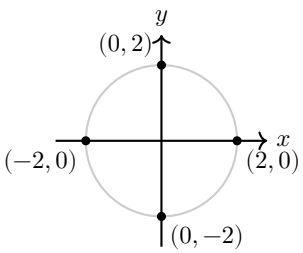

	$Y = -2$	$Y = 0$	$Y = 2$
$X = -2$	0	$\frac{1}{4}$	0
$X = 0$	$\frac{1}{4}$	0	$\frac{1}{4}$
$X = 2$	0	$\frac{1}{4}$	0

Найдите коэффициент корреляции и проверьте случайные величины на зависимость.

Пример: решение

Маргинальные распределения:

x	-2	0	2
$P(X=x)$	$\frac{1}{4}$	$\frac{1}{2}$	$\frac{1}{4}$

y	-2	0	2
$P(Y=y)$	$\frac{1}{4}$	$\frac{1}{2}$	$\frac{1}{4}$

$E[X] = (-2)\cdot\frac{1}{4} + 0\cdot\frac{1}{2} + 2\cdot\frac{1}{4} = 0, \quad E[Y] = (-2)\cdot\frac{1}{4} + 0\cdot\frac{1}{2} + 2\cdot\frac{1}{4} = 0.$

Во всех исходах произведение $XY = 0$, поэтому $E[XY] = 0$ и

$$Cov(X,Y) = E[XY] - E[X]E[Y] = 0 \implies Corr(X,Y) = 0.$$

Зависимость — проверка через произведение маргинальных вероятностей, например для пары $(0,-2)$:

$$P(X=0, Y=-2) = \frac{1}{4}, \qquad P(X=0)\,P(Y=-2) = \frac{1}{2}\cdot\frac{1}{4} = \frac{1}{8} \neq \frac{1}{4}.$$

Значит X и Y зависимы (хотя $Corr(X,Y) = 0$).