Теория вероятностей и математическая статистика

Многомерное нормальное распределение. Центральная предельная теорема.

Глеб Карпов

Программы БИ, УЦП, ТАДвБ ВШБ ВШЭ.

Напоминание: Линейная комбинация случайных величин

Предположим, что у нас есть X и Y — две случайные величины. Следующие свойства работают для любой возможной природы этих переменных.

1. Линейное свойство математического ожидания: $E[aX \pm bY] = aE[X] \pm bE[Y]$.
2. Дисперсия линейной комбинации: $Var[aX \pm bY] = a^2 Var[X] + b^2 Var[Y] \pm 2ab\Big(E[XY] - E[X]E[Y]\Big)$.
3. Если X и Y независимы: $Var[aX \pm bY] = a^2 Var[X] + b^2 Var[Y]$.

Многомерное нормальное распределение

Definition

Пара случайных величин (X, Y) имеет **двумерное нормальное распределение**, если для всех $a, b \in \mathbb{R}$ линейная комбинация $aX + bY$ имеет одномерное нормальное распределение.

Definition

Вектор случайных величин $\mathbf{X} = (X_1, X_2, ..., X_n)$ имеет **многомерное нормальное распределение**, если для всех векторов $\mathbf{a} \in \mathbb{R}^n$ линейная комбинация $\mathbf{a}^\top \mathbf{X}$ имеет одномерное нормальное распределение.
$\mathbf{a}^\top \mathbf{X} = a_1 X_1 + a_2 X_2 + ... + a_n X_n$

Устойчивость нормального распределения

- **Ключевое свойство**: Нормальное распределение **устойчиво** относительно линейных преобразований.
- Если $X \sim \mathcal{N}(\mu, \sigma^2)$, то для любых констант $a \neq 0$ и b:

$$Y = aX + b \sim \mathcal{N}(a\mu + b, a^2\sigma^2)$$

- **Интерпретация**: Линейное преобразование нормальной случайной величины даёт нормальную случайную величину.

Устойчивость нормального распределения

Линейная комбинация двух независимых нормальных величин

Пусть $X_1 \sim \mathcal{N}(\mu_1, \sigma_1^2)$, $X_2 \sim \mathcal{N}(\mu_2, \sigma_2^2)$ независимы, и $Y = aX_1 + bX_2$.

1. **Характеристики** (работают для любых случайных величин):

$$E[Y] = a\mu_1 + b\mu_2, \qquad \mathrm{Var}(Y) = a^2\sigma_1^2 + b^2\sigma_2^2.$$

2. **Тип распределения**: независимые нормальные (X_1, X_2) задают двумерное нормальное распределение, поэтому $Y = aX_1 + bX_2$ тоже нормальна.
3. **Параметры**: у нормального закона параметры совпадают с матожиданием и дисперсией, значит

$$Y \sim \mathcal{N}(a\mu_1 + b\mu_2,\ a^2\sigma_1^2 + b^2\sigma_2^2).$$

Частный случай $a = b = 1$: $X_1 + X_2 \sim \mathcal{N}(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2)$.

Устойчивость нормального распределения

Обобщение на n переменных

Пусть $X_1, \dots, X_n$ независимы и $X_i \sim \mathcal{N}(\mu_i, \sigma_i^2)$, а $Y = \sum_{i=1}^n a_i X_i$.

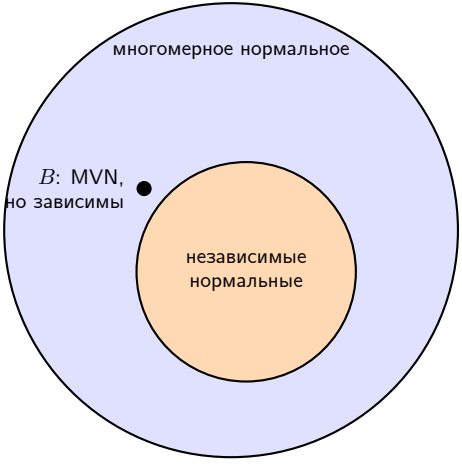
1. **Характеристики** (по свойствам E и Var):

$$E[Y] = \sum_{i=1}^n a_i \mu_i, \qquad \mathrm{Var}(Y) = \sum_{i=1}^n a_i^2 \sigma_i^2.$$

2. **Тип распределения**: набор независимых нормальных величин имеет многомерное нормальное распределение, поэтому любая линейная комбинация Y нормальна.
3. **Параметры**: раз параметры нормального закона — это как раз $E[Y]$ и $\mathrm{Var}(Y)$, получаем

$$Y \sim \mathcal{N}\left(\sum_{i=1}^n a_i \mu_i,\ \sum_{i=1}^n a_i^2 \sigma_i^2 \right).$$

Логика высказываний: независимость и многомерное нормальное



Независимые нормальные величины всегда дают многомерное нормальное распределение (внутренний круг).
Обратное неверно: бывает многомерное нормальное с зависимыми компонентами (точка B).

Точка B: многомерное нормальное, но зависимые

Как считать параметры линейной комбинации

Пусть (X, Y) — двумерное нормальное, $E[X] = \mu_X$, $E[Y] = \mu_Y$, $\mathrm{Var}(X) = \sigma_X^2$, $\mathrm{Var}(Y) = \sigma_Y^2$, и $\mathrm{Cov}(X, Y) = \sigma_{XY} \neq 0$ (компоненты зависимы). Рассмотрим $T = aX + bY$.

1. **Характеристики** (общие формулы; независимость не нужна):

$$E[T] = a\mu_X + b\mu_Y, \qquad \mathrm{Var}(T) = a^2\sigma_X^2 + b^2\sigma_Y^2 + 2ab\,\sigma_{XY}.$$

   Появился «перекрёстный» член $2ab\,\sigma_{XY}$: если бы X и Y были независимы, он бы исчез.
2. **Тип**: раз (X, Y) многомерно нормально, то $T = aX + bY$ нормальна.
3. **Параметры**: у нормального закона они совпадают с характеристиками, поэтому

$$T \sim \mathcal{N}(a\mu_X + b\mu_Y,\ a^2\sigma_X^2 + b^2\sigma_Y^2 + 2ab\,\sigma_{XY}).$$

Ковариационная матрица

Параметры второго порядка пары (X, Y) записывают в виде **ковариационной матрицы**

$$\Sigma = \begin{pmatrix} \mathrm{Var}(X) & \mathrm{Cov}(X,Y) \\ \mathrm{Cov}(Y,X) & \mathrm{Var}(Y) \end{pmatrix} = \begin{pmatrix} \sigma_X^2 & \sigma_{XY} \\ \sigma_{XY} & \sigma_Y^2 \end{pmatrix}.$$

- На диагонали стоят дисперсии, вне диагонали — ковариации.
- Матрица симметрична: $\mathrm{Cov}(X,Y) = \mathrm{Cov}(Y,X)$.
- При независимости X и Y имеем $\sigma_{XY} = 0$, и Σ диагональна (внутренний круг на предыдущем слайде).
- При $\sigma_{XY} \neq 0$ матрица недиагональна: это как раз точка B — многомерное нормальное с зависимыми компонентами.

Дисперсия линейной комбинации тогда записывается компактно: для $\mathbf{a} = (a, b)^\top$

$$\mathrm{Var}(aX + bY) = \mathbf{a}^\top \Sigma \mathbf{a}.$$

Пример

Двумерное нормальное с ненулевой ковариацией

Пусть (X, Y) имеет двумерное нормальное распределение,

$$E[X] = 2, \quad E[Y] = 6, \quad \mathrm{Var}(X) = 4, \quad \mathrm{Var}(Y) = 4, \quad \mathrm{Cov}(X, Y) = \tfrac{1}{2}.$$

1. Запишите ковариационную матрицу Σ.
2. Найдите распределение суммы $T = X + Y$.
3. Вычислите $P(X + Y > 11)$.

Решение.

$$\Sigma = \begin{pmatrix} \mathrm{Var}(X) & \mathrm{Cov}(X, Y) \\ \mathrm{Cov}(Y, X) & \mathrm{Var}(Y) \end{pmatrix} = \begin{pmatrix} 4 & 1/2 \\ 1/2 & 4 \end{pmatrix}.$$

Характеристики суммы:

$$E[T] = E[X] + E[Y] = 2 + 6 = 8,$$
$$\mathrm{Var}(T) = \mathrm{Var}(X) + \mathrm{Var}(Y) + 2\,\mathrm{Cov}(X, Y) = 4 + 4 + 2 \cdot \tfrac{1}{2} = 9.$$

Так как (X, Y) двумерно нормально, $T \sim \mathcal{N}(E[T], \mathrm{Var}(T)) = \mathcal{N}(8, 9)$. Тогда

$$P(T > 11) = P\left(Z > \frac{11 - E[T]}{\sqrt{\mathrm{Var}(T)}}\right) = P\left(Z > \frac{11 - 8}{3}\right) = P(Z > 1) = 1 - \Phi(1).$$

Иллюстративный пример

Функция от двух дискретных случайных величин

Предположим, что мы бросаем два 6-гранных кубика, независимых друг от друга. В итоге мы наблюдаем дискретный случайный вектор (X, Y), где X и Y — случайные величины, соответствующие выпавшим числам на каждом из кубиков. Поскольку существует 36 различных пар, совместная функция вероятности задается как: $P(X = x_i, Y = y_j) = \frac{1}{36}$.

Введем новую случайную величину T как функцию от X и Y: $T = f(X, Y) = X + Y$. Построим функцию вероятности для случайной величины T.

Иллюстративный пример

Построение функции вероятности для $T = X + Y$

Для каждого значения t случайной величины T найдем все пары (x, y), которые дают в сумме t:

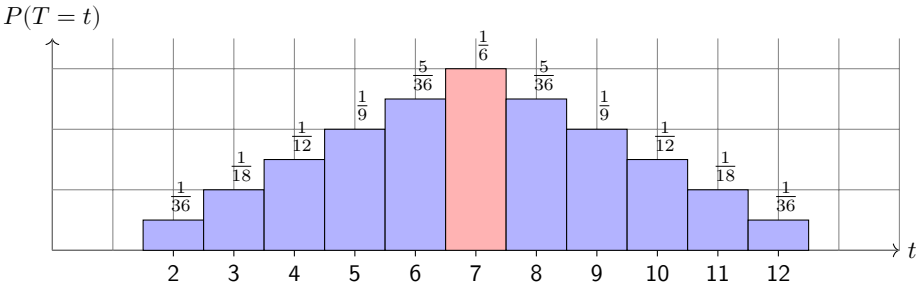
- $T = 2$: только $(1, 1)$
- $T = 3$: $(1, 2), (2, 1)$
- $T = 4$: $(1, 3), (2, 2), (3, 1)$
- $T = 5$: $(1, 4), (2, 3), (3, 2), (4, 1)$
- $T = 6$: $(1, 5), (2, 4), (3, 3), (4, 2), (5, 1)$
- $T = 7$: $(1, 6), (2, 5), (3, 4), (4, 3), (5, 2), (6, 1)$
- $T = 8$: $(2, 6), (3, 5), (4, 4), (5, 3), (6, 2)$
- $T = 9$: $(3, 6), (4, 5), (5, 4), (6, 3)$
- $T = 10$: $(4, 6), (5, 5), (6, 4)$
- $T = 11$: $(5, 6), (6, 5)$
- $T = 12$: только $(6, 6)$

Иллюстративный пример

Таблица функции вероятности

t	2	3	4	5	6	7	8	9	10	11	12
$P(T=t)$	$\frac{1}{36}$	$\frac{1}{18}$	$\frac{1}{12}$	$\frac{1}{9}$	$\frac{5}{36}$	$\frac{1}{6}$	$\frac{5}{36}$	$\frac{1}{9}$	$\frac{1}{12}$	$\frac{1}{18}$	$\frac{1}{36}$

График функции вероятности



Промежуточный вывод

Мы на очень простом примере можем пронаблюдать, как функция вероятности суммы одинаково распределенных дискретных величин получает “усиление” в центральных значениях, так как к этим элементарным исходам приводят больше комбинаций изначальных величин.

Центральная предельная теорема

Предпосылки

- Пусть $X_1, X_2, \ldots$ — последовательность независимых случайных величин, взятых из одного и того же распределения, т.е. все X_i имеют одинаковое математическое ожидание $E[X] = \mu$, одинаковую дисперсию $Var[X] = \sigma^2 < \infty$.
- Мы конструируем **новую** случайную величину как частичную сумму первых n случайных величин X_i:

$$S_n = \sum_{i=1}^{n} X_i.$$

- Согласно свойствам математического ожидания и дисперсии, характеристики новой случайной величины:

$$E[S_n] = E\Big[\sum_{i=1}^{n} X_i\Big] = \sum_{i=1}^{n} E[X_i] = n\mu$$

$$Var[S_n] = Var\Big[\sum_{i=1}^{n} X_i\Big] = \sum_{i=1}^{n} Var[X_i] = n\sigma^2$$

Центральная предельная теорема

- **Центральная предельная теорема**: распределение такой случайной величины S_n стремится к нормальному распределению при $n \to \infty$:

$$S_n \to Y \sim \mathcal{N}(n\mu, n\sigma^2)$$

- Душно:

$$\forall x \in \mathbb{R} \quad P(S_n < x) \underset{n\to\infty}{\longrightarrow} P(Y < x), \text{ где } Y \sim \mathcal{N}(n\mu, n\sigma^2),$$

что означает, что в каждой точке x функция распределения $F_{S_n}(x)$ стремится к функции распределения $F_Y(x)$, т.е. они буквально "накладываются" друг на друга и теперь характеризуют одну и ту же случайную величину.

- Проще говоря: $S_n \sim \mathcal{N}(n\mu, n\sigma^2)$, когда n достаточно велико.
- Обычно "достаточно велико" это $n \geq 30$.

Центральная предельная теорема

Формулировка через стандартизацию

- Проводим операцию стандартизации введенной ранее случайной величины S_n:

$$Z_n = \frac{S_n - E[S_n]}{\sqrt{Var[S_n]}} = \frac{S_n - n\mu}{\sigma\sqrt{n}}$$

- Характеристики:

$$E[Z_n] = E\left[\frac{S_n - n\mu}{\sigma\sqrt{n}}\right] = E\left[\frac{S_n}{\sigma\sqrt{n}}\right] - E\left[\frac{n\mu}{\sigma\sqrt{n}}\right] = \frac{n\mu}{\sigma\sqrt{n}} - \frac{n\mu}{\sigma\sqrt{n}} = 0$$

$$Var[Z_n] = Var\left[\frac{S_n - n\mu}{\sigma\sqrt{n}}\right] = Var\left[\frac{S_n}{\sigma\sqrt{n}}\right] + Var\left[\frac{n\mu}{\sigma\sqrt{n}}\right] = \frac{Var[S_n]}{n\sigma^2} + 0 = 1$$

- Тогда говорим, что:

$$\forall x \in \mathbb{R} \quad P(Z_n < x) \underset{n\to\infty}{\longrightarrow} P(Z < x), \text{ где } Z \sim \mathcal{N}(0,1)$$

Или проще: стандартизованная частичная сумма $Z_n \sim \mathcal{N}(0,1)$, когда n достаточно велико. Обычно требуем $n \geq 30$.

Напоминание: Биномиальное распределение

- Пусть $X \sim \text{Bin}(n, p)$ — биномиальная случайная величина.
- X можно представить как сумму n независимых бернуллиевских случайных величин:

$$X = X_1 + X_2 + ... + X_n, \quad \text{где } X_i \sim \text{Bernoulli}(p)$$

- Характеристики:
  - $E[X] = np$
  - $\text{Var}(X) = np(1-p)$

Интегральная теорема Муавра-Лапласа (ИТМЛ)

Theorem

Пусть $X \sim \text{Bin}(n, p)$. При больших n биномиальное распределение приближается нормальным:

$$X \sim \mathcal{N}(np, np(1-p))$$

Условия: n достаточно велико (обычно $n \geq 30$), и желательно $np > 5$ и $n(1-p) > 5$; или в эквивалентной форме $npq \geq 25$, где $q = 1 - p$.
Это частный случай ЦПТ для суммы бернуллиевских случайных величин!

Нормализованная форма ИТМЛ

- Нормализованная случайная величина:

$$Z = \frac{X - np}{\sqrt{np(1-p)}}$$

- При больших n:

$$Z \sim \mathcal{N}(0, 1)$$

- Это позволяет использовать стандартную нормальную таблицу для вычисления вероятностей биномиального распределения!

Применение ИТМЛ: вычисление вероятностей

- Для биномиального распределения $X \sim \mathrm{Bin}(n, p)$:

$$P(a \le X \le b) \approx P\left(\frac{a - np}{\sqrt{np(1-p)}} \le Z \le \frac{b - np}{\sqrt{np(1-p)}} \right),$$

где $Z \sim \mathcal{N}(0, 1)$.

Пример: применение ИТМЛ

- Пусть $X \sim \text{Bin}(100, 0.3)$. Найти $P(25 \leq X \leq 35)$.
- **Точное вычисление** (через биномиальное распределение):

$$P(25 \leq X \leq 35) = \sum_{k=25}^{35} \binom{100}{k} (0.3)^k (0.7)^{100-k} \approx 0.7698$$

- **Приближение через нормальное распределение**:
  - Параметры: $\mu = np = 30$, $\sigma^2 = np(1-p) = 21$, $\sigma \approx 4.58$

$$\begin{aligned} P(25 \leq X \leq 35) &\approx P\left(\frac{25-30}{4.58} \leq Z \leq \frac{35-30}{4.58}\right) \\ &= P(-1.09 \leq Z \leq 1.09) \\ &\approx 0.7242 \end{aligned}$$

- **Сравнение**: Нормальное приближение даёт результат 0.7242, близко к точному значению 0.7698.