Теория вероятностей и математическая статистика

Введение в задачу статистики. Точечные оценки и их свойства. Выборочное среднее.

Глеб Карпов

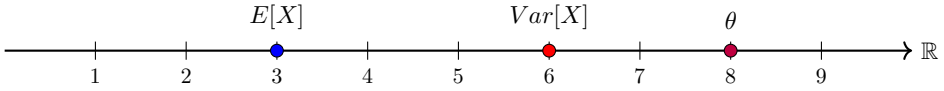
Программы БИ, УЦП, ТАДвБ ВШБ ВШЭ.

Введение в статистику

- Хотим открыть магазин определенного вида товаров. Первичная задача: оценить средний доход в день, чтобы планировать бизнес. В соседнем районе есть похожий магазин, и мы пользуемся старым добрым промышленным шпионажем, чтобы собрать информацию о доходах такого магазина.
- Если формализовать, X - случайная величина, доход магазина в день. Каждый день мы получаем некую её **реализацию** x. На основе собранных $(x_1, \dots, x_n)$ реализаций хотим узнать, как минимум, неизвестное $E[X]$, i.e. средний доход магазина в день.
- Случайные процессы вокруг нас — запаянные чёрные ящики со случайными генераторами внутри. Мы хотим "расшифровать" один такой ящик и выяснить его параметры и/или характеристики, например, математическое ожидание и дисперсию. Для этого мы наблюдаем случайную величину некоторое количество раз и затем делаем выводы на основе накопленной информации.

Введение в статистику: визуализация

Идеальная ситуация: мы знаем параметры и/или характеристики



Реальная ситуация: параметры и/или характеристики неизвестны

Значения будто скрыты от нас туманом



Что изучает статистика?

- Статистика — это совокупность процедур и принципов для сбора и анализа информации с целью принятия решений в условиях неопределенности.
- В теории вероятностей мы идем от предполагаемой модели к вероятности конкретного исхода, т.е. от общего к частному. В статистике задачи решаются почти полностью в обратном направлении. Статистика исследует относительно небольшой конкретный исход, и цель — узнать что-то о глобальных свойствах случайного эксперимента.
- Таким образом, несмотря на тесную связь между вероятностью и статистикой — между ними прослеживается четкое различие.

Случайная выборка и её реализация

- Собранные данные обычно называются выборкой, но в статистике мы одновременно имеем дело с двумя различными типами выборок.
- Случайная выборка — это вектор (коллекция, набор, совокупность) независимых и одинаково распределенных (i.i.d.) случайных величин:

$$\mathcal{X} = (X_1, X_2, \dots, X_n), \quad f_{X_i}(x) = f_{X_j}(x), \ \forall i, j \in [1, n], \forall x.$$

- Реализация случайной выборки — это набор наблюдений из случайной выборки $\mathcal{X}$, набор конкретных чисел:

$$x = (x_1, x_2, \dots, x_n).$$

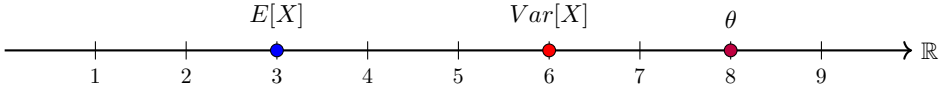
- Генеральная совокупность (популяция) — полное множество объектов, обладающих интересующим признаком, несущих реализацию интересующей нас случайной величины. Извлекая наблюдения из генеральной совокупности, мы можем сформировать реализацию выборки.

Статистики как случайные величины

- **Статистика** — не только название курса, но и любая функция, зависящая только от переменных случайной выборки, т.е. $g = g(X_1, \dots, X_n)$.
- Каждая статистика будет принимать новое значение для новой реализации $(x_1, \dots, x_n)$ случайной выборки по сравнению с предыдущей реализации выборки.
- Поэтому мы рассматриваем статистики как случайные величины! Как случайные величины, они имеют свои собственные распределения и характеристики. Вероятностное распределение статистики $Y = g(X_1, \dots, X_n)$ называется **выборочным распределением** для Y.

Точечные оценки

Идеальная ситуация: мы знаем параметры и/или характеристики



Реальная ситуация: параметры и/или характеристики неизвестны

Значения будто скрыты от нас туманом



- Параметры и характеристики случайной величины — числа, **точки** на числовой оси. Семейство методов для угадывания этих значений обычно называется **точечной оценкой**.

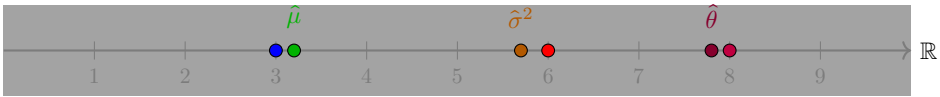
Точечные оценки

- **Оценка** — это специальная статистика, функция от случайной выборки. Её реализация может быть использована в качестве кандидата-значения, **предположения** о значении какого-либо параметра неизвестной случайной величины.
- Пусть θ — неизвестный параметр случайной величины (например, μ или σ^2). Тогда оценка: $\widehat{\theta} = \widehat{\theta}(X_1, \dots, X_n)$, функция от случайной выборки, тоже является случайной величиной.
- **Реализация оценки** — конкретное числовое значение, полученное из конкретного наблюдения выборки.

Цель точечной оценки

- На основе реализации случайной выборки $x_1, x_2, \dots, x_n$ получить **предположения** $\hat{\theta}$ для скрытых в тумане параметров
- Идея состоит в том, чтобы посчитать значение оценки на имеющихся данных, и чтобы полученное число было бы как можно ближе к истинным значениям параметров
- Следуя аналогии, мы хотим найти затерянные в тумане точки, путём их угадывания специальным способом, с помощью функции **оценки**.

В идеале реализации точечных оценок $\hat{\mu}$, $\hat{\sigma}^2$
и $\hat{\theta}$ "попадают" близко к истинным значениям



Смещенность и несмещенность

Definition

Оценка $\hat{\theta}$ называется **несмещенной**, если:

$$E[\hat{\theta}] = \theta$$

Оценка $\hat{\theta}$ называется **смещенной**, если:

$$E[\hat{\theta}] \neq \theta$$

Смещение (bias) определяется как:

$$\text{Bias}(\hat{\theta}) = E[\hat{\theta}] - \theta$$

Среднеквадратичная ошибка (MSE)

Definition

Среднеквадратичная ошибка (Mean Squared Error, MSE) оценки $\hat{\theta}$ определяется как:

$$\text{MSE}(\hat{\theta}) = E[(\hat{\theta} - \theta)^2]$$

- MSE измеряет средний квадрат отклонения оценки от истинного значения параметра.
- **Разложение MSE**:

$$\text{MSE}(\hat{\theta}) = \text{Var}(\hat{\theta}) + [\text{Bias}(\hat{\theta})]^2$$

- MSE учитывает как дисперсию оценки, так и её смещение, и является неким "мерилом" качества точечной оценки. Чем меньше MSE, тем лучше работает точечная оценка.

Разложение MSE

$$\begin{aligned}\mathrm{MSE}(\hat{\theta}) = E[(\hat{\theta}-\theta)^2] &= E\Big[\big(\,\hat{\theta}-E[\hat{\theta}]\;+\;E[\hat{\theta}]-\theta\,\big)^2\Big] \\ &= E\Big[\;(\hat{\theta}-E[\hat{\theta}])^2\;+2\;(\hat{\theta}-E[\hat{\theta}])\;\cdot\;(E[\hat{\theta}]-\theta)\;+\;(E[\hat{\theta}]-\theta)^2\;\Big] \\ &= E\Big[\;(\hat{\theta}-E[\hat{\theta}])^2\;\Big]+E\Big[2\;(\hat{\theta}-E[\hat{\theta}])\;\cdot\;(E[\hat{\theta}]-\theta)\;\Big]+E\Big[\;(E[\hat{\theta}]-\theta)^2\;\Big]\end{aligned}$$

Математическое ожидание от константы остаётся самой константой:

$$E\Big[(E[\hat{\theta}]-\theta)^2\Big] = (E[\hat{\theta}]-\theta)^2, \quad E\Big[E[\hat{\theta}]-\theta\Big] = E[\hat{\theta}]-\theta.$$

Перекрёстное слагаемое исчезает, так как один из его множителей обращается в ноль:

$$E\Big[\;\hat{\theta}-E[\hat{\theta}]\;\Big] = E[\hat{\theta}]-E[E[\hat{\theta}]] = E[\hat{\theta}]-E[\hat{\theta}] = 0.$$

Поэтому

$$\mathrm{MSE}(\hat{\theta}) = E\Big[\;(\hat{\theta}-E[\hat{\theta}])^2\;\Big] + (E[\hat{\theta}]-\theta)^2 \;=\; \mathrm{Var}(\hat{\theta}) \;+\; [\mathrm{Bias}(\hat{\theta})]^2\,.$$

Состоятельность оценки

Definition

Оценка $\hat{\theta}$ называется **состоятельной**, если при увеличении размера выборки $n \to \infty$ оценка "сходится" к истинному значению параметра θ.

- **Интуиция**: Чем больше данных мы собираем, тем точнее становится наша оценка, тем ближе "в тумане" мы находим значения параметров.
- При $n \to \infty$ оценка должна становиться сколь угодно близкой к истинному значению параметра.
- **Важно**: Состоятельность — это асимптотическое свойство (при больших выборках).
- **Связь с несмещённостью**: Несмещённая оценка с дисперсией, стремящейся к нулю при $n \to \infty$, является состоятельной.
- Заметим, что состоятельная оценка может быть смещённой для малых выборок, но смещение должно исчезать при росте n.

Свойства основных оценок

Выборочное среднее

Предположим наличие случайной i.i.d. выборки $\mathcal{X} = (X_1, X_2, \dots, X_n)$ с $\mu \equiv E[X_i]$, $\sigma^2 \equiv \mathrm{Var}[X_i]$.

Выборочное среднее $\bar{X} = \frac{1}{n}\sum_{i=1}^{n} X_i$. Из свойств:

$$E[\bar{X}] = E\left[\frac{1}{n}\sum_{i=1}^{n} X_i\right] = \frac{1}{n}\sum_{i=1}^{n} E[X_i] = \frac{1}{n}\cdot n \cdot \mu = \mu,$$

$$\mathrm{Var}(\bar{X}) = \mathrm{Var}\left(\frac{1}{n}\sum_{i=1}^{n} X_i\right) = \frac{1}{n^2}\sum_{i=1}^{n} \mathrm{Var}(X_i) = \frac{1}{n^2}\cdot n \cdot \sigma^2 = \frac{\sigma^2}{n}.$$

Свойства основных оценок

Выборочное среднее: смещённость и MSE

Оценка $\bar{X}$ параметра μ:

- Смещение:

$$\mathrm{Bias}(\bar{X}) = E[\bar{X}] - \mu = \mu - \mu = 0.$$

  Значит, $\bar{X}$ — **несмещённая** оценка μ.

- Среднеквадратичная ошибка:

$$\mathrm{MSE}(\bar{X}) = \mathrm{Var}(\bar{X}) + \left(\mathrm{Bias}(\bar{X})\right)^2 = \frac{\sigma^2}{n} + 0 = \frac{\sigma^2}{n}.$$

- При $n \to \infty$ имеем $\mathrm{MSE}(\bar{X}) \to 0$, поэтому $\bar{X}$ — **состоятельная** оценка μ.